

基于大模型智能体的心理学调查仿真系统项目

1. 摘要

构建一个“数字化心理实验室”：批量生成具有指定人格/情境的人设智能体，让其完成标准心理量表作答，并自动输出心理测量学分析（如信度/效度、组间差异、相关矩阵与可视化），用于低成本的群体心理仿真实验。

2. 背景与动机

- 传统心理学实验成本高**：招募大样本被试耗时耗资；本项目尝试用 API 调用在分钟级生成可分析的大样本仿真数据。
- 研究/应用价值**：可在不触碰真人伦理风险的前提下，对高压/极端情境进行“社会预演”，快速做假设检验与方法论验证。

3. 项目目标与研究问题

- 仿真可信度**：LLM 是否能“听懂人设”，并在量表维度上呈现可检验的组间差异？
- 稳定性**：同一人设智能体在清除记忆后复测，结果是否稳定（复测信度）？
- 情境效应**：给定压力情境，人设是否会在相关量表上显著偏离常模/对照？
- 工程可用性**：能否形成“人设→量表→仿真→统计→报告”的自动化闭环与可视化界面？

4. 系统总体方案

4.1 核心思想：Silicon Sampling + 参数化 Prompt

- 将 **Agent 视为参数化 Prompt 配置**（而非独立程序）；通过循环调用同一 LLM API 批量采样形成“硅基被试”。
- 数据流：人设库（JSON/Excel）→ Prompt 组装（Python）→ LLM API → 解析与清洗 → 统计分析 → 报告与可视化。

4.2 模块划分

- 人设生成/管理模块**：定义年龄、职业、人格特征、经历背景、（可选）当前状态；支持批量导入/生成。
- 量表题库模块**：可扩展量表题库（含反向计分、维度映射、评分区间）。
- 仿真引擎（批量推理）**：按 Agent×题目循环调用；输出解析为结构化数据。
- 数据清洗与一致性检查**：输出格式校验、缺失/异常处理；（可选）冲突触发“反思重采样”。
- 统计分析模块**：信度/效度、组间检验、复测相关、效应量与可视化。
- 报告与可视化模块**：自动生成图表与结论摘要；提供基础交互界面（如 Streamlit）。

4.3 技术栈

Python 3.10+；Pandas/NumPy；scipy/pingouin；factor_analyzer；Streamlit；模型通过 DeepSeek 或 OpenAI API 调用。

5. 关键方法：推理阶段优化

目标：**不重训模型**，通过提示工程与控制流降低刻板化/随机性，提高仿真数据的信度与效度。

1. **Few-shot (少样本示例锚定)**：用 1–3 个示例固定语气与评分标尺，降低随机漂移。
2. **CoT (内心独白→打分)**：先生成“心理活动/自我反思”，再给 1–5 分，兼得定量分数与可分析的定性文本。
3. **动态状态注入**：将“当前情绪/疲劳”等状态写入 Prompt，并随题序更新，模拟测验过程中的状态累积效应。
4. **自洽性检验 + 反思重采样**：当回答与人设明显冲突时，触发批评/反思并重答，减少脏数据。

6. 实验设计与评价指标

实验 I：结构效度 (Construct Validity)

- 设计：内向组 vs 外向组 (各 50)
- 量表：大五人格量表 (BFI)
- 检验：外向性维度得分差异 (t-test, $p < 0.05$; 报告效应量)

实验 II：复测信度 (Test-Retest Reliability)

- 设计：同一批 Agent, T1 与清除记忆后的 T2 复测
- 指标：两次得分 Pearson 相关 (目标 > 0.7)

实验 III：情境模拟 (Scenario Simulation)

- 设计：设定“期末考试且挂科风险极大”的大学生情境
- 量表：SAS (焦虑自评量表)
- 预期：得分显著高于常模/对照组 (并报告效应量与置信区间)

统一输出

- 维度得分分布、组间差异检验、复测相关、(可选) Cronbach's α
- 题项/维度相关矩阵
- CoT 文本的基础分析 (词频/主题/聚类, 作为“拟人推理”的证据)

7. 数据与实现细节

7.1 数据结构

- `personas.xlsx/json`: age、occupation、personality、background、state...
 - 建议字段最小集: `agent_id`, `group_label`(实验分组), `persona_text`(人设摘要), `scenario_id`(情境), `baseline_state`(情绪/压力/疲劳), `seed`(可选)
 - 批量生成时建议保留: `prompt_version` (用于复现实验)、`created_at` (追溯)
- `scales/`: 题目、反向计分、维度映射、评分区间
 - 建议补充字段: `scale_id`, `item_id`, `dimension`, `reverse(bool)`, `likert_min`, `likert_max`
 - 反向题统一在计分阶段处理 (例如 1–5: $x' = 6 - x$)
- `responses.csv`: `agent_id`、`scale_id`、`item_id`、`score`、`cot_text`、`timestamp`、`meta`
 - 建议将 `meta` 中记录: 模型名、temperature、top_p、重试次数、解析是否成功、(如触发) 反思重采样原因

7.2 输出格式规范

为保证可解析与可复现，统一输出：

- 心理活动：...
- 分数：x

(可选更稳做法) 统一为 JSON 输出，字段至少包含：agent_id, scale_id, item_id, dimension, score, cot，便于批处理与校验。

7.3 质量控制

- 格式校验 + 自动重试；记录失败原因（例如：缺字段/分数越界/无法解析）。
- 分数校验：score 必须落在量表评分区间 [likert_min, likert_max]；否则判为无效并重试。
- 冲突检测触发反思重答；保留重采样日志用于方法部分说明（例如：人设/情境与回答明显矛盾）。
- 可复现记录：每次实验运行保存 run_config（模型、温度、prompt_version、样本量、分组规则、时间戳）。
- 计分与统计（落地口径）：
 - 先按题库规则反向计分，再按维度聚合得到维度总分（sum/mean 二选一并固定）。
 - 信度：对每个维度计算 Cronbach's α （可选补充 McDonald's ω ）；复测信度用 T1/T2 维度得分相关（Pearson 或 Spearman）。
 - 效度：已知组（内向/外向）做组间差异检验（t-test 或 Mann-Whitney），并报告效应量（Cohen's d）；输出维度相关矩阵（热力图）作为结构/收敛区分证据。

8. 评分维度映射

- 选题价值 / 研究意义：强调“低成本群体仿真”“高风险情境社会预演”“方法论验证”
- 研究设计 / 分析过程：三组实验 + 心理统计指标 + 可复现实验流程
- 研究结论：给出可推广的系统框架与可复用的推理优化策略；说明局限与后续工作

9. 预期成果

1. 可运行系统：批量人设、可选量表、自动统计分析与报告、基础可视化界面
2. 三个核心实验结果：结构效度、复测信度、情境模拟（含统计检验与图表）
3. 可复用资产：Prompt 模板、人设/量表配置格式、推理阶段优化策略说明与实验脚本

10. 参考论文

- Argyle et al., *Out of One, Many: Using Language Models to Simulate Human Samples* (Silicon Sampling)
- Park et al., *Generative Agents: Interactive Simulacra of Human Behavior* (生成式智能体：记忆/反思/规划)
- Miotto et al., *Who is GPT-3? An Exploration of Personality, Values and Demographics* (LLM 心理量表评估范式参考)